

面向跨模态数据融合细粒度特征的个性化服装推荐

田保军 康 萌 房建东

(内蒙古工业大学信息工程学院 内蒙古 呼和浩特 010080)

摘 要 服装已经成为网络购物的重要商品之一,实现精准的符合用户个性化审美的服装推荐系统,已经成为热门研究内容。针对提取用户的细粒度兴趣特征不全面,导致推荐系统的准确性低问题,提出融合长短期偏好的服装推荐算法;针对数据稀疏以及数据单一性,导致推荐结果个性化、多样性低的问题,利用跨模态数据和注意力机制使模型学习出更为精准的差异性用户特征。在真实数据集 Clothing Shoes and Jewelry 上,将所设计的模型 (PCR) 与经典的循环神经网络 RNN、基于矩阵分解 MF-BPR 模型以及改进的矩阵分解 TARMF 模型进行性能对比,PCR 模型在关键性能评价指标 NDCG、Precision@ K 和 Recall@ K 均有提升。实验结果表明该模型在服装推荐系统中是可行与有效的。

关键词 服装推荐 个性化 跨模态数据 细粒度兴趣 注意力机制

中图分类号 TP3 文献标志码 A DOI:10.3969/j.issn.1000-386x.2025.11.007

PERSONALIZED CLOTHING RECOMMENDATION FOR CROSS-MODAL DATA AND FINE-GRAINED INTERESTS

Tian Baojun Kang Meng Fang Jiandong

(College of Information Engineering, Inner Mongolia University of Technology, Hohhot 010080, Inner Mongolia, China)

Abstract Clothing has become one of the important commodities in online shopping, and the realization of accurate clothing recommendation meeting user's personalized aesthetic has become a popular research topic. Aiming at the problem that the fine-grained interest features extracted from users are not comprehensive, which leads to the low accuracy of the recommender system, this paper proposes a clothing recommendation algorithm integrating long-term and short-term preferences. To solve the problem of sparse and single data leading to low personalization and low diversity of recommendation results, this paper used cross-modal data and attention mechanism to make the model learn more accurate and differential user characteristics. On the real data set of Clothing Shoes and Jewelry, performance of the designed model (PCR) was compared with the classical recurrent neural network, the MF-BPR model and the TARMF model. The key performance evaluation indexes of the PCR model were improved in NDCG, Precision@ K and Recall@ K. The experimental results show that the model is feasible and effective in the clothing recommendation.

Keywords Clothing recommendation Personalization Cross-modal data Fine-grained interests Attention mechanism

0 引 言

随着经济的快速增长和社会的进步,人们更趋向于追求符合自己个人审美的时装。如何有效地根据用户个体穿衣风格的差异性,为其精准推荐符合需求的多样性服装已经成为该领域的关键研究内容之一^[1]。

推荐系统的核心是推荐算法,其通过对用户行为进行建模捕获到用户特征,利用该特征与候选项目的特征进行相似度的计算,最后根据计算得分向用户进行推荐^[2-3]。在服装推荐系统的研究领域中,高雄^[4]提出了一种协同过滤的服装推荐算法,该算法引入信任因子,通过计算用户间的信任关系生成最终推荐。Hu 等^[5]通过用户的购买记录来计算商品间的相似度,

收稿日期:2023-03-06。内蒙古自治区自然科学基金项目(2023LHMS06008,2019MS06024);内蒙古自治区科技重大项目(2018ZD0302)。田保军,教授,主研领域:推荐系统。康萌,硕士生。房建东,教授。

同时相似度计算的精准性进行了改进,为用户推荐新的商品。Khodabandehlou 等^[6]将用户属性特征等数据进行构建用户-项目矩阵,然后使用余弦相似度对用户间的相似度计算,进而向用户进行推荐。Stefani 等^[7]计算趋势评分,向用户进行推荐时基于趋势评分产生推荐。Lei 等^[8]提出一种基于用户偏好和项目匹配的服装推荐系统,在处理用户评分数据时使用了 SVD++ 矩阵分解技术。Wibowo 等^[9]对用户约束数据应用矩阵分解技术,使用极小函数调和和方法对得到预测评分进行组合。

目前,面向机器学习与深度学习已经成为服装推荐系统领域的主流方法。Su 等^[10]用分类支持向量机来对人脸表情进行分类,其中支持向量机用于对高维数据进行非参数分类,再使用卷积神经网络来计算用户的多兴趣值,实现了服装推荐。Jo 等^[11]提出了一种服装检索与推荐系统,使用生成对抗网络和卷积神经网络实现检索,其中卷积神经网络主要用于处理图像格式的数据。Lin 等^[12]提出利用卷积神经网络对服装的属性信息进行提取,其根据服装特征与用户特征的相似度得分向用户进行服装推荐。Xu 等^[13]对输入的服装图像使用语义分割算法进行特征提取,然后使用哈希函数对其进行处理,最后使用注意力机制实现服装推荐系统的构建。

通过对国内外研究现状分析,服装推荐算法主要存在以下问题:(1)用户的行为应该具有长期偏好与短期偏好的特性,忽略用户细粒度的兴趣特征,从而导致推荐系统的准确性低;(2)数据稀疏以及数据单一性(仅利用评分数据、文本数据或者图像数据进行特征提取),导致用户特征表示的多样性低,使得推荐结果缺乏个性化与差异性。

针对上述问题,本文提出一种面向多模态数据融合长短期偏好的用户细粒度特征的个性化服装推荐系统。其中,长期偏好是利用基于隐式反馈的注意力机制指导门控循环单元网络模型从用户历史评论中提取;短期偏好是利用基于历史评论的注意力机制指导深度卷积 VGGNet 网络从用户浏览过、满足时间阈值的服装图像中获取。

1 相关理论

1.1 深度卷积网络 VGGNet

卷积神经网络(Convolutional Neural Network, CNN)通常由两部分构成,分别为卷积操作部分和全连接部分。卷积操作部分通常由卷积层、池化层和 Dropout 层

等组成;全连接部分由堆叠的全连接层构成。网络的输出结果通常由 Softmax 激活函数计算得出。

作为一种经典的卷积神经网络,VGGNet 模型是由 L 个的卷积层(每个卷积层后加 ReLU 函数)、 M 个最大池化层、 N 个的全连接层以及用于输出结果的 Softmax 层构成,它对神经网络的深度与模型的性能进行了较优的平衡。与传统的深度卷积神经网络相比,VGGNet 模型具有以下优点:网络结构都使用的是大小相同的卷积核和最大池化尺寸,结果分类错误率少,模型的拓展性好以及模型泛化能力强等。

1.2 门控循环单元 GRU 网络

循环神经网络(Recurrent Neural Network, RNN)以链状的形式连接所有的循环单元,然后在序列的演进方向上进行递归,是一种递归型的神经网络。循环神经网络通常用来处理序列型数据,由于该网络具有记忆性、参数共享以及图灵完备,因此,其擅长学习序列信息,对序列型数据具有较强的拟合能力。相较于传统的循环神经网络而言,在较长的序列型数据上,门控循环单元网络(Gated Recurrent Unit, GRU)表现出了更好的性能。GRU 模型(如图 1 所示)的结构简单,它的参数相比长短期记忆网络(Long Short-term Memory, LSTM)少了近 1/3,因此其运行时间更短,效率更高,且不容易过拟合。




图1 GRU 模型

门控循环单元网络的核心公式如下:

重置门:

$$R_t = \sigma(X_t W_{xr} + H_{t-1} W_{hr} + b_r) \quad (1)$$

式中: $X_t \in \mathbf{R}^{n \times d}$, $W_{xr} \in \mathbf{R}^{d \times h}$, $W_{hr} \in \mathbf{R}^{d \times h}$, $b_r \in \mathbf{R}^h$ 。

更新门:

$$Z_t = \sigma(X_t W_{xz} + H_{t-1} W_{hz} + b_z) \quad (2)$$

式中: $W_{xz} \in \mathbf{R}^{d \times h}$, $W_{hz} \in \mathbf{R}^{h \times h}$, $b_z \in \mathbf{R}^h$ 。

候选隐藏:

$$\tilde{H}_t = \tanh(X_t W_{xh} + (R_t \odot H_{t-1}) W_{hh} + b_h) \quad (3)$$

式中: $\tilde{H}_t \in \mathbf{R}^{n \times h}$, $W_{xh} \in \mathbf{R}^{d \times h}$, $W_{hh} \in \mathbf{R}^{h \times h}$, $b_h \in \mathbf{R}^h$, $\odot$ 表示哈达玛乘积(Hadamard Product),即矩阵间对应元素相乘。

更新 t 时刻的隐藏状态:

$$\mathbf{H}_t = \mathbf{Z}_t \odot \mathbf{H}_{t-1} + (1 - \mathbf{Z}_t) \odot \tilde{\mathbf{H}}_t \quad (4)$$

在实际的任务场景中,为了能够同时捕捉序列数据的前置或后置特征,增强语义关联,将两个单独的 GRU 模型进行组合后得到 Bi-GRU 网络,其输出由这两个 GRU 的状态共同决定,即在每个 t 时刻,这两个相反方向的 GRU 会同时获得当前时刻的输出,将结果进行拼接作为最终输出。

1.3 注意力机制

为了解决序列模型中编码器-解码器存在的缺陷, Bahdanau 等^[14]首次提出了注意力 (Attention) 的概念。注意力机制的作用是使模型可以有选择性地关注数据中重要的部分,从而忽略掉与目前应用系统无关的噪声部分。在编码层对所有的隐藏状态使用注意力机制,这不仅可以保障最后一个隐藏层可以包含全部输入的信息,而且可以保证在解码时,对于每个词会产生不同的贡献度,从而能够反映源语句和目标语句中具有不同关联度的词。注意力机制的核心是从大量信息中筛选出重要的数据对其聚焦,其权重表示内容的重要程度,即权重越大,表示信息越重要。

注意力机制有三个核心的元素:Query、Key 以及 Value。其中,Query 向量表示给定目标序列中的某个元素,源序列由 Key 向量和 Value 向量组成,如图 2 所示。注意力的计算过程可以划分为三个步骤:(1) 对于给定的 Query 向量,通过式(5)计算得到其与每个 Key 向量之间的相似度即权重系数;(2) 对权重系数采用式(6)进行归一化;(3) 根据上一步得到的权重系数使用式(7)对 Value 值进行加权求和计算。

$$\text{sim}_i(\text{Key}_i * \text{Query}) = \text{Query} * \text{Key}_i \quad (5)$$

$$a_i = \text{softmax}(\text{sim}_i) = \frac{e^{\text{sim}_i}}{\sum_{j=1}^n e^{\text{sim}_j}} \quad (6)$$

$$\text{Attention} = \sum_{i=1}^n a_j * \text{Value}_i \quad (7)$$




图2 注意力的计算流程

2 本文模型

用户特征的精准性直接决定推荐系统的性能,因此,本文提出面向多模态数据融合细粒度特征的个性化服装推荐模型(Personalized clothing recommendation, PCR)。

2.1 长期偏好模型

本文以历史评论文本和隐式反馈(例如:点击、收藏等)作为用户的长期偏好。相较于传统的评分数据,评论文本具有更丰富的包含用户对项目的评价情感信息,它直观地叙述了用户购买商品的原因,有助于模型更好地学习到项目的特征。首先采用门控循环单元网络和词级别的注意力机制对用户评论文本进行建模,从而获取基于每条评论的用户局部特征;然后将用户隐式反馈作为注意力对评论层面建模,将捕获到用户的全局特征作为长期偏好。模型结构如图3所示。




图3 长期偏好模型

给定用户 u 和其历史评论文本序列(每个用户仅保留 N 条评论) $R_u = \{r_1, r_2, \dots, r_N\}$, 其中 $r_i = \{t_1, t_2, \dots, t_s\}$ (每条评论仅保留 s 个单词)。

(1) 用户的局部特征。

首先使用预训练 BERT 模型对单词进行嵌入表示,然后将这个嵌入单词序列输入到双向 GRU 模型中,得到其在词级别上下文的特征 $S_i = \{t'_1, t'_2, \dots, t'_s\}$, $t'_i \in \mathbf{R}^l$, $S_i \in \mathbf{R}^{l \times s}$ 。再将每个评论数据集中服装的类型 id (one-hot 向量) 编码到低秩特征空间中。即:

$$id^{1 \times l} = id^{1 \times n} \times M^{n \times l} \quad 1 \leq k \leq N$$

式中: $M^{n \times l}$ 是一个可学习的参数矩阵。

为了使每条评论都聚焦与其相关服装特征,因此将服装的类型 ID 作为 Query 向量,利用词级别注意力

机制捕获用户的精准局部特征 $s_i \in \mathbf{R}^l (1 \leq i \leq N)$, 则用户 u 所有评论构成的特征矩阵为 $\mathbf{T}_u = \{s_1, s_2, \dots, s_N\}$, ($\mathbf{T}_u \in \mathbf{R}^{l \times N}$), 其计算公式如下:

$$\gamma_i = \text{softmax}(id \times \mathbf{S}_i) \quad \gamma_i \in \mathbf{R}^{1 \times s} \quad (8)$$

$$s_i = \gamma_i \times \mathbf{S}_i^T \quad (9)$$

(2) 用户的全局特征。

假设用户集合 $U = \{u_1, u_2, \dots, u_m\}$, 项目集合 $I = \{i_1, i_2, \dots, i_n\}$, 根据用户的历史交互记录, 构建表示其全局行为的隐式反馈矩阵 $\mathbf{R} = [r_{ui}]^{m \times n}$ 。给定用户 $u \in U$ 和项目 $i \in I$, 若用户 u 与项目 i 存在交互行为, 则 $r_{ui} = 1$, 否则 $r_{ui} = 0$; $r_{:,i}$ 代表所有对项目 i 的历史反馈, 类似地, $r_{u,:}$ 代表用户 u 的所有历史反馈, 它可以表示用户 u 的全局行为。将 $\mathbf{R}^{m \times n}$ 利用矩阵分解方法进行降维^[15], 从而得到表示用户隐特征的低秩向量: $\mathbf{I}_u \in \mathbf{R}^d$ 。

将能够表示用户全局行为的隐特征 $\mathbf{I}_u$ 作为评论级注意力机制的 Query 向量, 从而捕获用户长期偏好特征向量 $\mathbf{s}_u \in \mathbf{R}^l$, 其计算公式如下:

$$\beta = \text{softmax}(\mathbf{T}_u^T \mathbf{W}_u \mathbf{I}_u) \quad \beta \in \mathbf{R}^n \quad (10)$$

$$\mathbf{s}_u = \beta \mathbf{T}_u^T \quad (11)$$

式中: $\mathbf{W}_u \in \mathbf{R}^{l \times d}$ 是权重参数。

2.2 短期偏好模型

随着时间迁移以及受客观因素的影响, 用户兴趣也会产生一定的变化, 因此, 如果只是考虑较为稳定的长期偏好, 会降低推荐系统的准确性。用户短时间内的交互行为可以反映用户当前的真实需求。服装图像作为一种服装类商品语义信息的表示, 提供文本里无法获取的特征信息, 而且更能直观地反映用户的审美和兴趣偏好, 不仅有效缓解数据稀疏性问题, 而且提高了推荐结果的个性化和可解释性, 进一步提高系统的性能。

本文采用 16 层 VGGNet 网络 (13 个卷积层与 3 个全连接层) 提取图像特征。首先, 将用户浏览时间大于阈值 ($\xi \geq 30$ s) 的原始服装图像的尺寸缩放为 224×224 ; 再将每个图像切分成 d 块; 然后, 采用预训练的 VGG-16 模型对服装图像分别对 d 块图像进行特征提取; 最后, 将 VGGNet 网络的全连接层的输出作为图像块 d 的特征向量, 即 $\mathbf{I}_f = [v_1, v_2, \dots, v_r]$, $f = 1, 2, \dots, d$, 如图 4 所示。




图4 提取图像块特征

为了避免同一个图像对于不同用户具有相同的特征, 导致推荐结果多样性差的问题。本文将用户的评论特征 $\mathbf{s}_u \in \mathbf{R}^l$ 作为 Query 向量, 利用注意力机制去指导生成个性化的图像特征, 该方法不仅可以去掉噪声而且可以有效提取到个性化的用户偏好, 同时通过模型学习到的注意力权重表示不同用户对同一个服装的不同关注度, 增加了推荐结果的可解释性。其计算过程如下:

(1) 用户 u 的初始图像特征矩阵为: $\mathbf{I}_u = (I_1, I_2, \dots, I_d) \in \mathbf{R}^{r \times d}$ 。

(2) 用户 u 长期偏好特征向量为 $\mathbf{s}_u \in \mathbf{R}^l$ 。

(3) 用户 u 的个性化图像特征向量: $\mathbf{u}_s \in \mathbf{R}^d$ (短期偏好), 其计算公式为:

$$\mathbf{A}_f = \text{softmax}(\mathbf{I}_u^T \mathbf{M}_f \mathbf{s}_u^T) \quad (12)$$

式中: $\mathbf{M}_f \in \mathbf{R}^{r \times l}$ 是参数矩阵, $\mathbf{A}_f \in \mathbf{R}^d$ 是注意力权重。

$$\mathbf{u}_s = \mathbf{I}_u \mathbf{A}_f \quad (13)$$

2.3 模型训练

通过线性变换将短期与长期偏好拼接, 得到用户 u 的细粒度特征向量 $\mathbf{u}_i \in \mathbf{R}^n$:

$$\mathbf{u}_i = \mathbf{W}_{u_i} [\mathbf{u}_s; \mathbf{s}_u] + b_i \quad (14)$$

式中: $\mathbf{W}_{u_i} \in \mathbf{R}^{n \times (r+l)}$ 是权重参数, $b_{u_i} \in \mathbf{R}^n$ 是偏置项。

最后, 利用 Sigmoid 激活函数产生最终的推荐结果, 计算公式如下:

$$\sigma(t) = \frac{1}{1 + e^{-t}} \quad (15)$$

$$\sigma(u_i) \in \mathbf{R}^n \quad (16)$$

当用户 u 与服装项目 i 存在交互行为 (例如: 点击、收藏等) 时, 记为 $r_{ui} = 1$, 否则 $r_{ui} = 0$ 。训练时, 使用正则化对数损失定义模型的损失函数, 如式 (17) 所示。

$$J = -\frac{1}{N} \left(\sum_{r_{ui}=1} \log \sigma(u_i) + \sum_{r_{ui}=0} \log (1 - \sigma(u_i)) \right) + \frac{\lambda}{2} \|\theta\|^2 \quad (17)$$

式中: σ 为 Sigmoid 激活函数, 它负责将 u_i 转化为相应概率分布值, λ 表示正则化参数。模型进行训练时, 采用随机梯度下降法对目标函数优化, 它随机地从训练集中选取训练数据, 使模型权重不断地朝着梯度的反方向进行迭代更新。本文使用两种正则化方法来对模型的复杂性进行控制, 一是采用 $L2$ 正则化 (λ 是正则化参数), 二是采用丢弃率为 50% 的 Dropout, 可以有效地防止模型过拟合。

3 实验设计与结果分析

3.1 实验环境

GPU 采用 Nvidia Tesla P100, 操作系统是 64 位的

Windows 10 企业版,编程环境为 PyCharm 2021.2.1 × 64,开发语言及框架分别是 Python 3.7.6 与 PyTorch 1.6.0。

3.2 评价标准

精确率 Precision 表示项目在模型生成的推荐列表中的位置和测试集中项目在列表中实际位置的交集,然后与该项目在推荐列表中位置进行相除。第 k 个项目的精确率表示如式(18)所示。

$$P_u@k = \frac{R(u) \cap T(u)@k}{R(u)@k} l_k \quad (18)$$

召回率 Recall 表示预测正确的项目数量占用户 u 真正购买的项目数量的比例,其衡量的是模型的查全率,如式(19)所示。

$$R_u@k = \frac{R(u) \cap T(u)@k}{T(u)@k} l_k \quad (19)$$

式中: $R(u)$ 表示推荐给用户 u 的项目集合, $T(u)$ 表示测试集中用户 u 真实交互的项目集合, l_k 表示在位置 k 处的项目用户是否交互过,若交互过则值为 1,否则为 0。

归一化折损累计收益 NDCG(Normalized Discounted Cumulative Gain)主要关注的是推荐列表中项目的顺序是否正确。项目列表中前 k 个位置的 DCG 值计算如式(20)所示。

$$DCG_{y,\pi}@k = \sum_{i=1}^k \frac{2^{y_{\pi_i}} - 1}{\log(i + 2)} \quad (20)$$

式中: $y = \{1, 2, \dots, r\}^n$ 表示项目评分向量, π_i 表示推荐列表中项目 i 的排名。理想状态 DCG* 表示评分低的项目都排在评分高的项目之后。NDCG 的值可以通过 DCG 值与 DCG* 值的比值得到,如式(21)所示。

$$NDCG_{y,\pi}@k = \frac{DCG_{y,\pi}@k}{DCG_{y,\pi_i}@k} \quad (21)$$

3.3 数据集

Amazon^[16] 是推荐系统领域中经典数据集,其中包含项目的评论信息和项目自身的元数据,该数据集中包括 Book、Clothing Shoes and Jewelry、Movies and TV 等子集,其稀疏度(density)为 5.16×10^{-4} 。本文实验使用 Clothing Shoes and Jewelr 数据子集(如表 1 所示),它包含了用户评论信息,服装商品的图像信息等。将数据集按照 8:1:1 的比例分为训练集、验证集与测试集。

表 1 数据集描述

数据集	用户数	项目数	评论数	评论词数
Amazon	24 195	19 643	231 183	8 658 491

3.4 实验结果分析

(1) 评论信息的特征向量维度。

图 5 中展示了向量维度在 {32、64、128、256、512} 变化时,对性能指标 Recall@5、Recall@20 和 Recall@50 产生的影响。从图中曲线的整体变化趋势可以看到,模型的性能随着维度的增加而不断提高,在维度是 512 上,模型的性能趋于平稳。




图 5 不同维度对模型性能影响

(2) 评论记录的长度。

本文实验测试了历史评论记录的长度在 {3, 5, 7, 9, 11, 13, 15} 范围内对于模型性能的影响,如图 6 所示。




图 6 不同评论记录长度对模型性能影响

分析实验结果数据可以得出以下结论:当历史评论记录长度处于 5 到 9 这个区间时,模型的性能达到较优的状态,即当历史评论记录长度较短时,由于信息不够充分导致模型难以从数据中学习知识,从而使性能不高;反之,当历史评论记录长度太大时,由于模型不能有效地过滤掉数据中的噪声,从而导致模型性能的下降。同时,从实验结果可知:随着 Epoch 数的增加,模型被训练得越来越好,性能指标也不断地提升。

(3) 与基线模型的性能比对。

在确定好模型的超参数后,在 Amazon 数据集上将 PCR 模型与目前的主流模型 MF-BPR^[17]、RNN^[18] 和 TARMF^[19] 进行性能的比对,结果如图 7-图 9 所示。




图7 不同模型的归一化折损累计收益值对比图




图8 不同模型的精确率对比图




图9 不同模型的召回率对比图

分析上述实验结果可以得出以下结论:在超参数相同的情况下,PCR模型在推荐系统的关键性能指标(NDCG、Precision和Recall)均优于基线模型,说明面向多模态数据融合长短期偏好的模型能有效捕获到用户的细粒度、多样性特征,它们对推荐结果质量的提升起到了关键作用。

4 结 语

针对提取用户的细粒度兴趣特征不全面,导致推荐系统的准确性低问题,以及数据稀疏以及数据单一性,导致推荐结果个性化、多样性低的问题。本文提出了一种面向跨模态数据融合长短期偏好的模型,实现了精准的符合用户个性化审美的服装推荐系统。在真实数据集 Amazon 的子集 Clothing Shoes and Jewelry 上,将本文所设计的 PCR 模型与经典的循环神经网络

RNN、基于矩阵分解 MF-BPR 模型以及改进的矩阵分解 TARMF 模型进行了性能比对,实验结果表明该模型在关键性能评价指标 NDCG、Precision@K 和 Recall@K 均有提升,为跨模态数据在服装推荐系统中研究与应用提供一种新的方法。

参 考 文 献

- [1] Yu W H, He X N, Pei J, et al. Visually aware recommendation with aesthetic features[J]. The International Journal on Very Large Data Bases, 2021, 4(30): 495-513.
- [2] Verbert K, Manouselis N, Ochoa X, et al. Context-aware recommender systems for learning: A survey and future challenges[J]. IEEE Transactions on Learning Technologies, 2012, 5(4): 318-335.
- [3] Wang S J, Cao L B, Wang Y, et al. A survey on session-based recommender systems[J]. ACM Computing Surveys, 2021, 54(7): 1-38.
- [4] 高雄. 基于协同过滤的服装个性化定制系统研究与实现[D]. 杭州: 浙江理工大学, 2019.
- [5] Hu Z H, Li X, Wei C, et al. Examining collaborative filtering algorithms for clothing recommendation in e-commerce[J]. Textile research Journal, 2019, 89(14): 2821-2835.
- [6] Khodabandehlou S, Golpayegani S, Rahman M. An effective recommender system based on personality traits, demographics and behavior of customers in time context[J]. Data Technologies Applications, 2020, 55(1): 149-174.
- [7] Stefani M A, Stefani V, Garofalakis J. CFRS: A trends-driven collaborative fashion recommendation system[C]//10th International Conference on Information, Intelligence, Systems and Applications, 2019: 1-4.
- [8] Lei Y, Chen L, Guan Z. Cloth recommender system based on item matching[C]//5th International Conference on Electrical Engineering, Control and Robotics, 2019, 533(1): 1-9.
- [9] Wibowo A T, Siddharthana A, Masthoff J, et al. Incorporating constraints into matrix factorization for clothes package recommendation[C]//26th Conference on User Modeling, Adaptation and Personalization, 2018: 111-119.
- [10] Su X P, Gao M, Ren J, et al. Personalized clothing recommendation based on user emotional analysis[J]. Discrete Dynamics in Nature and Society, 2020, 2020(1): 1-8.
- [11] Jo J, Lee S, Lee C, et al. Development of fashion product retrieval and recommendations model based on deep learning[J]. Electronics, 2020, 9(3): 508.
- [12] Lin Y R, Su W H, Lin C H, et al. Clothing recommendation system based on visual information analytics[C]//International Automatic Control Conference, 2019: 1-6.

(下转第 80 页)

分量、规律的周期分量、占比小的剩余分量,可以降低原始序列的波动性的影响,同时考虑到负荷的多周期特性,且能够有效地处理异常值,有利于提高电力负荷预测精度。

(2) 两阶段注意力 LSTM 模型,可以动态地提取对输入特征序列重要的特征信息和自动选择相关的时间步挖掘出历史时刻蕴含的有效信息,从而提升负荷预测精度。

(3) MSTL-TSALSTM 预测模型相比于其他预测模型具有更高的预测精度和稳定性。

在新型电力系统、大数据的背景下,加强负荷预测中影响因素的精细化处理分析,可以进一步提高预测的精度。后续可以进一步挖掘气象因素的空间特性,从而提升区域负荷预测性能。

参 考 文 献

- [1] 韩肖清,李廷钧,张东霞,等. 双碳目标下的新型电力系统规划新问题及关键技术[J]. 高电压技术,2021,47(9): 3036 - 3046.
- [2] 黄炜,陈田. 基于 SAE 与 CEEMDAN-BiLSTM 组合模型的短期电力负荷预测[J]. 计算机应用与软件,2022,39(7): 52 - 58.
- [3] 庄世杰,於志勇,郭文忠,等. 基于 Zoneout 的跨尺度循环神经网络及其在短期电力负荷预测中的应用[J]. 计算机科学,2020,47(9):105 - 109.
- [4] 张淑清,李君,姜安琦,等. 基于 FPA-VMD 和 BiLSTM 神经网络的新型两阶段短期电力负荷预测[J]. 电网技术,2022,46(8):3269 - 3279.
- [5] 李善寿,马泉杰,潘璐茜,等. 基于 VMD 和 LSTM-CNN 的短期负荷预测模型研究[J]. 控制工程,2023,30(3):469 - 478.
- [6] 胡威,张新燕,李振恩,等. 基于优化的 VMD-mRMR-LSTM 模型的短期负荷预测[J]. 电力系统保护与控制,2022,50(1):88 - 97.
- [7] 刘文杰,刘禾,王英男,等. 基于完整自适应噪声集成经验模态分解的 LSTM-Attention 网络短期电力负荷预测方法[J]. 电力建设,2022,43(2):98 - 108.
- [8] 刘亚辉,赵倩. 基于聚类经验模态分解的 CNN-LSTM 超短期电力负荷预测[J]. 电网技术,2021,45(11):4444 - 4451.
- [9] 张振中,郭傅傲,刘大明,等. 基于最大互信息系数和小波分解的多模型集成短期负荷预测[J]. 计算机应用与软件,2021,38(5):82 - 87.
- [10] 曾国钧,肖先勇,徐方维. 基于小波变换与 BiGRU-NN 模型的短期负荷预测方法[J]. 电测与仪表,2023,60(6): 103 - 109.
- [11] 朱凌建,荀子涵,王裕鑫,等. 基于 CNN-BiLSTM 的短期电力负荷预测[J]. 电网技术,2021,45(11):4532 - 4539.
- [12] 方娜,余俊杰,李俊晓,等. 基于 CNN-BiGRU-ATTENTION 的短期电力负荷预测[J]. 计算机仿真,2022,39(2):40 - 44,82.
- [13] 林涵,郝正航,郭家鹏,等. 基于 TCA-CNN-LSTM 的短期负荷预测研究[J]. 电测与仪表,2023,60(8):73 - 80.
- [14] Bandara K, Hyndman R J, Bergmeir C. MSTL: A seasonal-trend decomposition algorithm for time series with multiple seasonal patterns[J]. International Journal of Operational Research,2021,52(1):106 - 116.
- [15] Cleveland R B, Cleveland W S. STL: A seasonal-trend decomposition procedure based on loess[J]. Journal of official statistics,1990,6(1):70 - 73.
- [16] 王本涛,白杨,邢红涛,等. 基于 STL 与 MMoE 多任务学习的区域多光伏电站超短期功率联合预测方法[J]. 电力系统及其自动化学报,2022,34(9):17 - 23,31.
- [17] 李晓,卢先领. 基于双重注意力机制和 GRU 网络的短期负荷预测模型[J]. 计算机工程,2022,48(2):291 - 296,305.
- [18] 苏向敬,周汶鑫,李超杰,等. 基于双重注意力 LSTM 神经网络的可解释海上风电出力预测[J]. 电力系统自动化,2022,46(7):141 - 151.
- [19] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural Computation,1997,9(8):1735 - 1780.

(上接第 68 页)

- [13] Xu H, Bai M L, Wan T J, et al. Semantic analysis and retrieval recommendation of clothing image based on deep learning[J]. Basic Sciences Journal of Textile Universities, 2020,33(3):64 - 72.
- [14] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[C]//3rd International Conference on Learning Representations,2015:1473 - 1481.
- [15] Le D, Lauw H. Efficient retrieval of matrix factorization-based top-k recommendations: A survey of recent approaches[J]. Journal of Artificial Intelligence Research, 2021, 70(5):1441 - 1479.
- [16] Ni J M, Li J C, McAuley J. Justifying recommendations using distantly-labeled reviews and fine-grained aspects[C]//Empirical Methods in Natural Language Processing, 2019:188 - 197.
- [17] Rendle S, Freudenthaler C, Gantner Z, et al. BPR: Bayesian personalized ranking from implicit feedback[C]//25th Conference on Uncertainty in Artificial Intelligence,2009:452 - 461.
- [18] Yu F, Liu Q, Wu S, et al. A dynamic recurrent model for next basket recommendation[C]//29th International Conference on Research and Development in Information Retrieval, 2016:729 - 732.
- [19] Lu Y C, Dong R H, Barry S. Coevolutionary recommendation model: Mutual learning between ratings and reviews[C]//World Wide Web Conference,2018:773 - 782.