

DOI: 10.12477/j.att.202410033



官网下载



知网下载

基于扩散模型的多阶段一致可控虚拟试衣

孔东帅, 卢健, 孙鸿昱, 张曦文, 高惠雨

(大连大学信息工程学院, 大连 116622)

摘要:为解决现有扩散模型在虚拟试衣任务中难以保持服装纹理和色彩一致性的问题,提出了一种新的多阶段虚拟试衣方法。该方法包括两个阶段:在第一阶段,设计了一个基于多尺度特征注意力模块的服装形变网络,以抑制参考服装在形变过程中出现的纹理不自然现象,确保服装纹理和色彩的准确传递。在第二阶段,通过结合 ControlNet 和边缘与角落区域掩码,构建了一个局部修复网络,该网络可以在保持服装纹理细节的同时,专注于修复服装与人体的边界区域。结果表明:服装形变网络能够保持服装主干区域的色彩和纹理特征,局部修复网络能够填补人体和服装边界区域的纹理,从而提高虚拟试衣的真实感。相比现有虚拟试衣方法,该多阶段虚拟试衣方法在视觉一致性方面表现出优越的效果,提升了虚拟试衣体验。

关键词:虚拟试衣;扩散模型;一致性;ControlNet**中图分类号:**TS941;TP391.9**文献标志码:**A**文章编号:**1009-265X(2025)10-0077-09

基于图像的虚拟试衣任务是将服装参考图通过生成模型转移到目标人体图像中,尽管该技术近年来取得显著进展,但在实际应用中仍面临挑战。早期的虚拟试衣方法多依赖于生成对抗网络(Generative adversarial networks, GAN)^[1],其在处理复杂图案和细节丰富的服装时,生成图像质量不佳,这会影响试穿真实感和用户满意度^[2]。

扩散模型^[3]作为一种新兴的生成模型,在生成的图像质量上显示出超越 GAN 的潜力。扩散模型通过逐步引导数据分布从噪声状态转变为目标图像,在图像生成任务中表现出更优的性能。Morelli 等^[4]提出一种基于潜在扩散模型的虚拟试衣框架 LaDI-VTON,设计了一种可学习的跳跃连接结构来增强中间特征,并使用文本反转组件来调节服装纹理的合成,但该方法不能保持服装纹理的视觉一致性。为解决这一问题,Zhu 等^[5]提出并行 UNet 架构的虚拟试衣方法,该方法通过交叉注意力机制,直接将一个人体图像中的服装转移到另一个人体图像中,这种方法保持了试穿的真实性,但视觉一致性问

题并未完全解决。而 Gou 等^[6]使用服装形变模块预测服装的外观流场,然后将形变的服装与人体的服装遮罩图像结合,再使用扩散模型构建细化模块,去噪后得到进一步改进的结果,但该方法由于对人体图像进行全部重采样,服装的复杂纹理仍旧不能严格参考原始服装图像。

因此,如何保证服装形变网络中参考图像纹理的高质量传递,以及控制扩散模型在虚拟试衣任务中的随机性,从而保证试穿的真实性和一致性,成为需要解决的问题。本文提出一种多尺度特征注意力模块,该模块用于稳定服装纹理的一致性,然后构建局部修复网络,并基于 ControlNet 进行姿势控制,对局部内容进行补充和修复,用于保证合理的结果。从而为虚拟试衣技术在电子商务、时尚设计领域的实际推广提供了更优的解决方案。

1 外观流

基于图像的多阶段虚拟试衣方法^[7]通常将任务分解为服装形变和图像合成两个子任务:首先利

收稿日期:2024-10-16 网络出版日期:2025-04-16

基金项目:国家自然科学基金项目(U1708263)

作者简介:孔东帅(1998—),男,河南周口人,硕士研究生,主要从事扩散模型、图像处理等方面的研究

通信作者:卢健,E-mail:idu_du@163.com

用非刚性形变技术调整服装形态,然后应用生成模型(如 GAN 或扩散模型)进行重新采样,以获得真实的试衣效果。这种方法的优势在于可以更加真实地保留服装的纹理和色彩等信息,但在前后模块传递时可能造成细节损失,导致最终合成质量低下。

目前,在解决两阶段虚拟试衣中的服装非刚性形变问题上,主流方法有 3 种:基于外观流的估计方法^[8]、薄板样条变换(Thin-plate splines, TPS)^[9]和空间变换网络(Spatial transformer networks, STN)^[10]。与后两种方法相比,基于外观流的方法具有更高的自由度,能够实现更加灵活地形变。该方法通过神经网络来估计服装的像素特征从一个位置到另一个位置的密集映射关系,称为外观流。每个位置的外观流代表一个像素基于当前位置的偏移量,可以通过式(1)进行描述:

$$f(i, j) = N(i \pm u_i(i, j), j \pm u_j(i, j)) \quad (1)$$

式中:\$(i, j)\$表示一个基本像素位置,\$u_i(i, j)\$和\$u_j(i, j)\$表示该位置的像素在\$X\$和\$Y\$轴上的偏移量,\$N\$表示神经网络(Neural network)。这个公式表达了一个像素在空间位置上的变化,但不改变其原始的像素值。由于要计算每个像素位置的偏移,这种方式在一定程度上增大了训练开销,但是往往会得到相比传统 TPS 和 STN 更好的形变效果。

2 扩散模型与 ControlNet 网络

扩散模型是一类基于概率的生成模型,通过迭代去噪学习目标特征分布,可以生成细节丰富的高分辨率图像。与 GAN 相比,扩散模型在输出质量上表现更为优异。经典扩散模型分为正向的扩散过程和可训练的反向去噪过程,正向扩散过程通过将高斯噪声逐步添加到一张干净的图片中直至其成为一张符合正态分布的纯噪声图像,这是一个经典的马尔科夫过程,正向扩散过程递推方式使用式(2)描述:

$$x_t = \sqrt{\alpha_t} x_{t-1} + \sqrt{1 - \alpha_t} \epsilon_t \quad (2)$$

式中:\$\epsilon_t \sim N(0, I)\$,\$x_t\$表示第\$t\$步的数据,\$\alpha_t\$为控制噪声强度的超参数。在经过足够的迭代步数(例如\$T\$步)后,\$x_T\$将近似服从标准高斯分布\$N(0, I)\$。

反向去噪过程的目标是从高斯噪声分布\$x_T\$逐步还原出原始数据\$x_0\$。该过程也构成一个马尔可夫链,并使用式(3)描述:

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \alpha_t}} \epsilon_\theta(x_t, t) \right) + \sigma_t z \quad (3)$$

式中:\$z \sim N(0, I)\$,\$\sigma_t\$是控制每一步噪声大小的参数,\$\epsilon_\theta(x_t, t)\$是一个深度神经网络,用来预测在给定时刻\$t\$的噪声。反向扩散过程的重点在于学习一个可以预测噪声的神经网络\$\epsilon_\theta\$,从而能够逐步去噪,从噪声分布中生成新的数据样本。

ControlNet^[11]是一种专为增强扩散模型的控制能力而设计的网络结构,并已被应用到虚拟试衣任务中^[12]。该方法的核心思想是通过引入额外的控制条件,使扩散模型在生成过程中能够遵循特定的先验信息,如姿势图、边缘图或深度图等,从而提高生成结果的可控性。具体而言,ControlNet通过复制扩散模型的去噪网络的部分结构,并在特定数据集进行训练,使其能够学习控制信号与目标图像之间的映射关系。在训练过程中,原始去噪网络的权重保持冻结,仅对新增的ControlNet分支进行优化。这种训练策略的优势在于,既保留了原始模型生成高质量图像的能力,又增加了对图像内容的精细控制。此外,由于ControlNet仅对新增部分进行训练,而不影响原始去噪网络的参数,因此该方法具有较好的迁移性,不同架构的扩散模型均能通过该方式为视觉生成任务添加控制条件。

3 实验方法

首先,形式上给定一个原始人物图像\$I \in \mathbb{R}^{3 \times H \times W}\$和一个参考服装图像\$C \in \mathbb{R}^{3 \times H \times W}\$。本文的目标是先对参考服装图像\$C\$进行形变,然后将它们合成为一个逼真的新图像\$\hat{I} \in \mathbb{R}^{3 \times H \times W}\$,该图像中的人物形象将保留\$C\$的服装元素。因此,本文从基于多尺度特征注意力模块的外观流预测网络和使用ControlNet构建的局部修复网络两个部分来阐述。

3.1 基于多尺度特征注意力模块的外观流预测

在第一阶段,首先,对原始人物图像\$I\$解析得到对应的服装无关的分割映射图\$S_a \in \mathbb{R}^{3 \times H \times W}\$和密集姿势映射图\$densepose\$I_d \in \mathbb{R}^{3 \times H \times W}\$,其中\$S_a\$是虚拟试衣研究领域一种常见的对人体图像的分割结果,其将人体图像分割成不同的语义区域,如头部、上半身、下半身、手臂等,而不依赖于特定的服装类型;而\$I_d\$是一种由Meta AI提出的用于精确估计人体姿态的模型输出结果,它将二维图像中的每个像素映射到三维人体表面的相应位置,从而实现对人体姿态的详细描述。接着,使用编码器\$E_l\$和\$E_c\$分别对原

始图像解析结果(I_d 和 S_a)和参考服装图像(C)进行特征编码,其中 E_l 和 E_c 均为由下采样和残差网络(ResNet)组成的特征编码器,编码结果被送入特征金字塔网络,得到对应不同尺度的中间特征图 h_i ,将其作为本文提出的多尺度特征注意力(Multi-scale Feature Attention, MSFA)模块的输入,然后,在

每个尺度上,该模块都会输出一个外观流 f_i ,将其与前一个尺度的外观流融合,并通过双线性插值方式进行不断地采样,直至达到原始分辨率。如图1所示,将最终输出的外观流作用到参考服装 C 及其掩码 M 上,得到形变后的服装 C_w 及其对应的掩码 M_w 。




图1 第一阶段服装形变网络结构

Fig. 1 Structure of the clothing deformation network in the first stage

3.1.1 多尺度特征注意力模块

在计算特征金字塔网络每一个尺度的中间特征 h_i 后,本文针对每一个尺度的中间特征图,在将其与下一级特征融合时,应用通道注意力机制和空间注意力机制对其进行特征增强和融合。

首先,对于特征 h_i ,计算通道注意力权重 W_c ,并进行首次特征选择与强化,得到中间特征图 F_i ,使用式(4)描述:

$$F_i = \sigma(N(\text{Avg}(h_i)) + N(\text{Max}(h_i))) \odot h_i \quad (4)$$

式中:Avg和Max分别表示平均池化和最大池化操作, σ 表示sigmoid激活函数。然后,根据新的特征图计算空间注意力权重,得到最终增强的特征图,使用式(5)描述:

$$F'_i = \sigma(k^{7 \times 7}(\text{Avg}(F_i)) + k^{7 \times 7}(\text{Max}(F_i))) \odot F_i \quad (5)$$

式中: $k^{7 \times 7}$ 表示核大小为7的卷积操作。

通道注意力机制通过建模特征图中不同通道之

间的相互依赖关系,自适应地调整每个通道的权重,从而突出重要的通道特征信息并抑制无关通道的影响。空间注意力机制则通过建模特征图中不同空间位置之间的相互依赖关系,调整每个空间位置的权重,从而突出重要的空间区域并抑制无关的背景区域。

在融合后的特征图上,本文使用一个由多个卷积层组成的外观流估计网络来预测从服装图像到人体姿势的密集外观流映射关系。本文采用金字塔式的迭代优化策略,如图2所示,首先在最粗糙的尺度上预测一个初始外观流 f_1 。然后,将该外观流上采样到下一个更精细的尺度 f_2 ,并将其作为对应尺度的外观流初始值。在每个尺度上,该方法都会使用外观流估计网络来对前一个外观流进行优化。这个过程重复进行,直至达到原始分辨率,并将与服装尺度相同的外观流应用到参考服装 C 和其掩码 M ,得到 C_w 和 M_w 。




图2 外观流上采样示意图

Fig. 2 Schematic diagram of sampling on the appearance flow

3.1.2 损失函数与正则化

本文针对特征金字塔网络的每个尺度的特征图,使用一个平滑卷积层进行邻近像素之间的平滑处理,用以保证输出结果的平滑性。因此,除了基本的 VGG 损失和 L1 损失,本文也引入了总变分(Total-Variation, TV)损失和二阶平滑约束。

其中总变分损失($\mathcal{L}_{TV}$)是一种常用的正则化项,主要用于降低外观流场在上采样过程产生的误差,避免对图像中相邻像素值的影响,通过式(6)计算:

$$\mathcal{L}_{TV} = \sum_{n=1}^N \sum_p \sqrt{(\nabla_x I_p)_n^2 + (\nabla_y I_p)_n^2} \quad (6)$$

式中: N 表示金字塔网络的层数,实际代码中使用了5层不同大小的尺度。其中 $(\nabla_x I_p)_n$ 和 $(\nabla_y I_p)_n$ 分别表示在第 n 层的尺度图中,图像 I 在位置 p 处的水平和垂直方向上的梯度,用来衡量图像在水平方向和垂直方向上的变化幅度。

另外,本文还引入了二阶平滑约束。根据图5和图6,在参考图像中,通常包含一些密集纹理,如重复出现的条纹或一些细小的图案元素。如果服装形变过程中这些位置的像素流动差异过大,会导致极不自然的形变结果。二阶平滑约束($\mathcal{L}_{sec}$)用以增强临近位置外观流的共线性^[13],并通过式(7)计算:

$$\mathcal{L}_{sec} = \sum_{n=1}^N \sum_p \sum_{\pi \in N_p} P(f_n^{p-\pi} + f_n^{p+\pi} - 2f_n^p) \quad (7)$$

式中: f_n^p 表示外观流映射中的在第 n 层尺度上的第 p 个点, N_p 代表 p 点水平、垂直以及两条对角线上的邻居集合,而 P 表示一个广义的 Charbonnier 损失函数^[14],通常用于计算外观流的二阶差分。总的来说,本文所提出的方法的总的损失函数($\mathcal{L}_{All}$)通过式(8)表示:

$$\mathcal{L}_{All} = \lambda_1 \cdot \mathcal{L}_{L1} + \lambda_2 \cdot \mathcal{L}_{VGG} + \lambda_3 \cdot \mathcal{L}_{TV} + \lambda_4 \mathcal{L}_{sec} \quad (8)$$

式中: $\sum_{i=1}^4 \lambda_i = 1$ 。

3.2 局部修复网络

在第二阶段,首先,对原始人物图像 I 预处理得到服装遮罩图像 $I_a \in \mathbb{R}^{3 \times H \times W}$,然后,使用上一阶段得到的服装形变图像和遮罩 C_w, M_w 与服装遮罩图像 I_a 进行融合,得到待修复的图像 $z_{inpaint} \in \mathbb{R}^{3 \times H \times W}$ 及待修复区域的掩码 $z_{mask} \in \mathbb{R}^{1 \times H \times W}$ 。图3是本文第二阶段的训练流程框架,通过 $z_{inpaint}$ 和 z_{mask} ,本文构建了一个基于扩散修复模型的局部修复网络,由于待修复图像的遮挡部分可能涵盖复杂的姿态以及遮掩的纹理,本文通过 ControlNet 结构将密集姿势映射图像 I_d 和参考服装图像 C 作为条件信息输入到扩散模型的去噪网络中,用以指导生成过程。这种方法利用了原始模型的预训练能力,同时允许针对新任务的微调,从而在不需要使用较大计算量的情况下优化模型。




图3 基于 ControlNet 的局部修复网络训练框架

Fig.3 Training framework for the local refinement network based on ControlNet

另外,本文使用 DINO-v2 模型替换了原始扩散模型结构中的对比文本-图像对的预训练(Contrastive Language-Image Pre-training, CLIP)^[15]模型,DINO-v2 是 Meta AI 提出的一种采用无监督方式训练的视

觉 Transformer 模型,该模型不直接使用图像文本对的形式来训练图像编码,而是通过将图像编码为全局令牌(token)和补丁令牌,这样可以保留更多的像素信息,并且表现出对图像中物体更加稳定的语义

理解和低级视觉特征的理解能力,这在指导去噪网络进行图像合成时可以实现更好的参考,因此,本文使用该模型作为 ControlNet 网络中参考服装 C 的特征提取模块。

针对人体图像的特定部位,如颈部(或领口)、手臂以及躯干的交叉区域,本文提出的方法可以结合语义以及条件输入的服装参考图与姿势信息,对此部分的像素进行修复,该方法尽可能保留了参考服装图像的主体部分,又能使得合成的图像语义上更加合理。最终,所提出的方法进行训练去噪网络的过程可以通过表达式(9)描述:

$$\mathbb{E}_{I, I_a, C, I_d, t, \epsilon} [\|\epsilon - \epsilon_\theta(x_t, I_a, C, I_d, t)\|_2^2] \quad (9)$$

式中: ϵ 表示局部修复网络的权重参数,通过给定人体图像 I , 在训练过程中向其添加噪声得到 z_t , t 表示添加噪声的次数。

通过给定的输入,包括带噪声图像 z_t 、待修复区域掩码 z_{mask} 、服装遮罩图像 I_a 以及额外的控制条件密集姿势映射 I_d 、参考服装图像 C , 不断微调网络使其能够尽可能还原出原始人体图像 I 。

4 结果与分析

4.1 数据集和评估标准

本文在 VITON-HD^[16-17] 虚拟试衣数据集进行了实验训练和评估。该数据集包含训练集和测试集,提供了配对数据(即服装图像与人像图像为对应关系)和非配对数据列表。配对数据由一组参考图像和与之相对应的人物图像组成,非配对数据则用于指导将人物图像与其他服装图像进行搭配。

VITON-HD 的训练集部分共有 11647 组数据,提供了原始人体图像对、服装和服装蒙版图像、密集姿势映射等数据。为加快训练和推理过程,本文实验预先对服装形变结果进行了计算并存储在数据集文件夹下。在训练和推理阶段,这些预处理数据将自动加载,无需额外计算,从而提高效率。

关于实验结果的评估标准,本文采用以下广泛使用的 4 个指标:FID(Fr chet Inception Distance)、KID(Kernel Inception Distance)、SSIM(Structural Similarity)和 LPIPS(Learned Perceptual Image Patch Similarity)。其中 FID 和 KID 分别用来评估生成图像和真实图像之间的差异以及生成图像和真实图像之间的相似性,本文使用这两个指标来衡量非配对数据的生成质量;SSIM 和 LPIPS 被用来评估图像之

间的相似性以及感知相似性,后者反映了人类视觉系统的感知特点,本文用这两个指标评估配对数据的生成结果。

4.2 实验设置

针对实验中两阶段的训练过程,本文分开执行训练步骤。该实验使用两块 NVIDIA GeForce RTX 3090 GPU 执行训练流程。其中关于服装形变网络,本文训练了 100 轮次。为了加快训练速度,在训练过程中,首先将图像下采样到 256×192 分辨率,在推理时,再重新将其采样到 512×384 分辨率,其中批大小设置为 32。在训练的前 50 个轮次中,本文将学习率设置为 5×10^{-5} ,在最后的 50 个轮次中,设置学习率逐渐减小到 0,这样做的目的是加快训练前期的收敛速度,后期再通过降低学习率进行小幅度权重微调。

在训练第二阶段局部修复网络时,本文训练了 200 轮次,其中将网络学习率设置为 2×10^{-5} ,批大小仅设置为 2。为了平衡质量和训练的速度,本文将采样步数设置为 50,这样能够尽可能保证服装和人体的语义边界区域的生成质量,使得试衣结果更加真实自然。

4.3 定性结果

在图 4 中,本文提出的方法在服装细节的保持和一致性上面优于其他几种方法。观察服装的主干部分的纹理细节和色彩,由于该方法保留了外观流估计方法形变的结果,所以可以最大限度保持纹理的一致性,再利用扩散模型可以进行语义边角区域高质量修复的优势,本文提出的方法的试衣结果更加忠实于参考服装图像。

图 5 展示了本文提出的方法与其他基于扩散模型方法在细小复杂服装纹理上的差异,从图中可以看到,对于包含文字和复杂图案的服装纹理,该方法能够较好地保持与参考图像对齐。在扭曲服装 C_w 与服装遮罩图像 I_a 进行融合后,本文提出的局部修复网络并未针对服装主干区域进行重新采样,在第二阶段中,局部修复网络的输入蒙版仅对应于融合后图像的服装和人体语义边界区域,因此可以保留服装主干区域的纹理细节,从而实现较高的保真度。

4.4 定量结果

针对定量结果,本文提出的方法在 VITON-HD 数据集上设置评估并与目前主流的基准方法进行对比。本文在配对数据上评估全部四个指标(SSIM、




图 4 在 VITON-HD 上的本文的方法与 SOTA 方法的定性比较

Fig. 4 Qualitative comparison between this paper's method and SOTA methods on VITON-HD



图 5 本文的方法与其他基于扩散模型的方法对比

Fig. 5 Comparison between this paper's method and other diffusion model-based methods

LPIPS、FID 和 KID), 并在未配对数据上, 评估 FID 和 KID 分数。可以看出, 本文提出的方法在 LPIPS、FID 和 KID 指标的测评中均比其他四种基于扩散的

方式获得更好的分数。定量结果表明, 本文提出的方法在多数评估指标中优于目前主流的基准方法, 在保持参考服装一致性方面实现新的 SOTA。

表 1 在 VITON-HD 数据集的量化结果对比

Tab. 1 Quantitative result comparison on the VITON-HD dataset

方法	SSIM _p ↑	LPIPS _p ↓	FID _p ↓	KID _p ↓	FID _u ↓	KID _u ↓
LaDI-VTON	0.861	0.0968	9.44	3.90	12.33	4.75
DCI-VTON	0.875	0.0816	8.19	2.93	12.07	3.35
CAT-DM	0.862	0.0803	8.11	1.72	10.65	2.07
TPD	0.895	0.0886	8.54	—	10.42	—
本文方法	0.877	0.0792	7.94	1.55	10.17	1.83

4.5 消融实验

为了验证本文提出的组件的有效性, 在图 6 中展示了消融实验的结果。首先, 针对服装形变网络中的多尺度特征注意力模块的有效性, 实验截取

第一阶段服装形变的结果进行对比, 观察图 6(a), 使用了 MSFA 模块的结果 (w/MSFA) 相比没有使用的结果 (w/o MSFA), 可以保持更好的纹理, 稳定了服装纹理在形变时的压缩现象。在图 6(b)

中,使用 MSFA 的结果从视觉上对比来看,消除了原始的纹理拉扯的影响,使得服装的效果更加自

然和连贯,图 7 中展示了更多本文提出的方法的试衣结果。



图 6 关于有无 MSFA 模块的消融实验结果

Fig. 6 Results of ablation experiments with and without MSFA module



图 7 补充试衣结果展示

Fig. 7 Supplementary try-on result display

在表 2 中量化结果的提升证明了提出的模块的有效性,由于本文在局部修复阶段保持了服装形变的主干区域,所以第一阶段形变效果可以直接影

响到最终的试衣效果。再经过局部修复模型的细化,本文提出方法的实验结果在视觉上实现了更好的参考一致性效果。

表 2 有无 MSFA 的量化结果对比

Tab. 2 Comparison of quantitative results with and without MSFA

模块使用	$SSIM_p \uparrow$	$LPIPS_p \downarrow$	$FID_p \downarrow$	$KID_p \downarrow$	$FID_u \downarrow$	$KID_u \downarrow$
w/o MSFA	0.862	0.810	8.15	1.72	10.67	1.97
w/MSFA	0.877	0.792	7.94	1.55	10.17	1.83

5 结论

本文提出了一种基于多尺度特征注意力的特征融合模块,用于优化基于外观流的服装形变过程,减少纹理不自然的现象,提高服装主干区域的纹理细节保留率。同时,结合 ControlNet 设计了一种局部

修复网络,以第一阶段形变服装为基础,利用密集姿势映射和参考图像进行条件控制,对服装与人体边界区域进行精细修补。该方法在保持服装整体纹理一致性的同时,增强了边界区域的合理性与自然性。实验结果表明,该方法在提升虚拟试衣视觉质量方面具有显著优势,能够有效改善服装纹理一致性问题。

尽管本文方法在提升试衣效果方面取得了较好的表现,但仍存在一些不足之处,如最终试穿结果易受到各阶段效果的叠加影响,对第一阶段网络训练质量要求较高。另外,未来研究可考虑引入更大规模数据集,以增强模型的泛化能力。最后,未来可探索将当前多阶段方法与端到端架构结合,在保证试衣质量的同时降低操作复杂度。

参考文献:

- [1] 施倩, 罗戎蕾. 基于生成对抗网络的服装图像生成研究进展[J]. 现代纺织技术, 2023, 31(2): 36-46.
- SHI Q, LUO R L. Research progress of clothing image generation based on Generative Adversarial Networks[J]. Advanced Textile Technology, 2023, 31(2): 36-46.
- [2] 阮艳雯, 施雨荷, 顾力文, 等. 人机交互感知对虚拟试衣体验满意度的影响[J]. 丝绸, 2023, 60(5): 87-96.
- RUAN Y W, SHI Y H, GU L W, et al. Influence of human-computer interaction perception on the satisfaction of virtual fitting experience[J]. Journal of Silk, 2023, 60(5): 87-96.
- [3] ROMBACH R, BLATTMANN A, LORENZ D, et al. High-resolution image synthesis with latent diffusion models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New Orleans, LA, USA. IEEE, 2022: 10684-10695.
- [4] MORELLI D, BALDRATI A, CARTELLA G, et al. LaDI-VTON: latent diffusion textual-inversion enhanced virtual try-on[C]//Proceedings of the 31st ACM International Conference on Multimedia. Ottawa ON, Canada. ACM, 2023: 8580-8589.
- [5] ZHU L, YANG D, ZHU T, et al. TryOnDiffusion: A tale of two UNets[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR). Vancouver, BC, Canada. IEEE, 2023: 4606-4615.
- [6] GOU J, SUN S, ZHANG J, et al. Taming the power of diffusion models for high-quality virtual try-on with appearance flow[C]//Proceedings of the 31st ACM International Conference on Multimedia. Ottawa ON, Canada. ACM, 2023: 7599-7607.
- [7] 赵娟, 魏雪霞, 徐增波. 基于深度学习的2D虚拟试衣技术研究进展[J]. 丝绸, 2021, 58(9): 48-52.
- ZHAO J, WEI X X, XU Z B. Research progress of 2D virtual fitting technology based on deep learning[J]. Journal of Silk, 2021, 58(9): 48-52.
- [8] 柳思雨. 基于流变换的虚拟试穿方法研究[D]. 杭州: 杭州电子科技大学, 2024.
- LIU S Y. Research on virtual try-on method based on flow[D]. Hangzhou: Hangzhou Dianzi University, 2024.
- [9] BOOKSTEIN F L. Principal warps: Thin-plate splines and the decomposition of deformations[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1989, 11(6): 567-585.
- [10] 薛涛, 曹哲睿, 周千明. 用于课堂行为识别的轻量化姿态估计网络研究[J]. 西安工程大学学报, 2024, 38(6): 124-134.
- XUE T, CAO Z R, ZHOU Q M. Research on lightweight pose estimation net works for classroom behavior recognition[J]. Journal of Xi'an Polytechnic University, 2024, 38(6): 124-134.
- [11] 杨道俊, 沈雷, 杨芳宇. 基于扩散模型的生成式人工智能服装设计[J]. 服装学报, 2025, 10(4): 311-319.
- YANG D J, SHEN L, YANG F Y. Diffusion model-based generative artificial intelligence generated content for fashion design[J]. Journal of Clothing Research, 2025, 10(4): 311-319.
- [12] 郭宇轩, 孙林. 基于扩散模型的 ControlNet 网络虚拟试衣研究[J]. 现代纺织技术, 2024, 32(3): 118-128.
- GUO Y X, SUN L. Virtual fitting research based on the diffusion model and ControlNet network[J]. Advanced Textile Technology, 2024, 32(3): 118-128.
- [13] GE Y, SONG Y, ZHANG R, et al. Parser-free virtual try-on via distilling appearance flows[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, TN, USA. IEEE, 2021: 8481-8489.
- [14] 丁焕, 侯珏, 杨阳, 等. 基于三维人体姿态信息的协作式扩散试衣生成网络[J]. 浙江理工大学学报(自然科学), 2024, 51(5): 691-704.
- DING H, HOU J, YANG Y, et al. A collaborative diffusion-based network for virtual try-on based on 3D human pose information[J]. Journal of Zhejiang Sci-Tech University (Natural Sciences), 2024, 51(5): 691-704.
- [15] 祖雅妮, 张毅. 基于大规模预训练文本图像模型的虚拟试穿方法[J]. 丝绸, 2023, 60(8): 99-106.
- ZU Y N, ZHANG Y. A virtual try-on method based on the large-scale pre-training text-image model[J]. Journal of Silk, 2023, 60(8): 99-106.
- [16] CHOI S, PARK S, LEE M, et al. VITON-HD: High-resolution virtual try-on via misalignment-aware normalization[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, TN, USA. IEEE, 2021: 14126-14135.
- [17] 朱欣娟, 徐晨澈. 基于风格迁移的虚拟试穿研究[J]. 纺织高校基础科学学报, 2023, 36(1): 65-71.
- ZHU X J, XU C W. Research on virtual try-on based on style transfer[J]. Basic Sciences Journal of Textile Universities, 2023, 36(1): 65-71.

Multi-stage consistent and controllable virtual try-on based on diffusion models

KONG Dongshuai, LU Jian, SUN Hongyu, ZHANG Xiwen, GAO Huiyu

(College of Information Engineering, Dalian University, Dalian 116622, China)

Abstract: With the rapid advancement of image generation technology, diffusion models have emerged as a dominant approach in the field of image synthesis and demonstrated significant potential across various application scenarios, with virtual try-on being one of its crucial application directions. Compared to traditional generative models, diffusion models excel in producing higher-quality images. However, due to their inherent randomness, it is challenging to ensure consistency between the generated try-on clothing and the reference clothing. Currently, despite extensive efforts to enhance consistency by incorporating conditional control into diffusion models, but they still face challenges such as accurately preserving clothing details and optimizing the integration quality between clothing and the human body. To address these issues, this paper proposes a multi-stage virtual try-on framework aimed at improving clothing consistency and enhancing the integration effect between clothing and the human body.

The proposed method consists of two primary stages. In the first stage, a clothing deformation network integrated with a multi-scale feature attention module is designed to reduce texture distortion during the clothing deformation process, improve the stability of clothing deformation, and enhance the ability to preserve detailed textures. In the second stage, a local refinement network based on ControlNet is introduced to perform detailed refinement on the boundary regions between clothing and the human body. By incorporating dense pose mapping and clothing reference images as additional control signals, this network can effectively reconstruct clothing details, achieving a more natural integration of clothing with the human body. Experimental results demonstrate that the proposed method offers significant advantages in maintaining clothing consistency while improving the realism of the try-on images. Ablation experiments and comparative analysis with current mainstream virtual try-on frameworks further validate the superiority of this approach in preserving clothing details and optimizing the clothing deformation effect.

The results indicate that this method has achieved significant improvements in enhancing the quality of virtual try-on, but there are still certain limitations. To streamline the workflow and improve overall try-on quality, future research will explore end-to-end training strategies and conduct training and testing on larger, more diverse datasets to enhance the model's generalization capability. By further optimizing the method and addressing existing challenges, this study aims to provide more reliable technical support for intelligent clothing design and digital clothing applications. The proposed method effectively tackles issues related to clothing deformation and detail preservation, significantly elevating the visual experience of virtual try-on and providing users with more realistic and reliable try-on effects. These improvements open up new possibilities for applications in intelligent clothing design, online shopping platforms, and digital clothing displays.

Keywords: virtual try-on; diffusion model; consistency; ControlNet